

构建下一代数据架构 释放 AI 的“数据智慧”

演讲人：江岚

瓴羊 / Dataphin建设平台技术负责人

AiCon
全球人工智能开发与应用大会

📍 北京

QCon

全球软件开发大会

会议时间：4月10-12日

- 大模型赋能 AIOps
- 越挫越勇的大前端
- 云上业务架构演进
- 多模态大模型及应用
- 海外 AI 应用创新实践

📍 北京

AiCon

全球人工智能开发与应用大会

会议时间：6月27-28日

- 端侧智能
- AI Agent
- 多模态大模型
- 金融+大模型

📍 上海

QCon

全球软件开发大会

会议时间：10月23-25日

- AI Agent
- 大模型训练推理
- 端侧 AI
- 搜推深度融合
- 数智金融

4月

5月

6月

8月

10月

12月

📍 上海

AiCon

全球人工智能开发与应用大会

会议时间：5月23-24日

- 通用大模型
- AI Agent
- 垂直领域应用
- 模型可解释性

📍 深圳

AiCon

全球人工智能开发与应用大会

会议时间：8月22-23日

- 模型效率与部署
- 多模态大模型
- 大模型安全
- 智能硬件

📍 北京

AiCon

全球人工智能开发与应用大会

会议时间：12月19-20日

- 通用大模型
- 智能硬件
- LMOPs
- 具身智能

极客邦科技 2025 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询



查看会议

十年磨一剑，源自阿里巴巴最佳实践



从阿里巴巴最佳实践，到服务千行百业



Dataphin智能数据建设与治理



目录

01

WHY: AI时代数据架构的挑战

02

WHAT: 现代数据架构的设计

03

HOW: 现代数据架构在产品中的落地

04

TODAY: Data for AI的总结与展望


01 AI时代数据架构的挑战



AI在企业中得到广泛使用

Organizations' use of AI has accelerated markedly in the past year, after years of little meaningful change.

Organizations that use AI in at least 1 business function,¹ % of respondents




¹In 2017, the definition for AI use was using AI in a core part of the organization's business or at scale. In 2018–19, the definition was embedding at least 1 AI capability in business processes or products. Since 2020, the definition has been that the organization has adopted AI in at least 1 function. Source: McKinsey Global Surveys on the state of AI

Organizations are increasingly using AI in multiple functions.

Business functions at respondents' organizations that are using AI,¹ % of respondents


• 2021 • 2022 • 2023 • First half of 2024 • Second half of 2024



¹In 2021, n = 1,843; in 2022, n = 1,492; in 2023, n = 1,684; in Feb–Mar 2024, n = 1,363; in July 2024, n = 1,491. The survey question asks about 11 functions: HR; IT; manufacturing; marketing and sales; product and/or service development; risk, legal, and compliance; service operations; software engineering; strategy and corporate finance; supply chain/inventory management; and other corporate functions (eg, knowledge management). Source: McKinsey Global Surveys on the state of AI, 2021–24

来源：The State of AI by McKinsey

数据是AI投产的重要影响因素



Proportion of respondents that identify AI life cycle stage as “most challenging”



Q. What stages of the AI/ML application life cycle are currently the most challenging (Rank 1)?
Base: All respondents (n=1,519).
Source: S&P Global Market Intelligence 451 Research Global Trends in AI custom survey, 2024.

Q. What are the primary challenges or impediments to moving an AI/ML application from proof-of-concept/piloting stages to production environments?
Base: All respondents (n=1,519).
Source: S&P Global Market Intelligence 451 Research Global Trends in AI custom survey, 2024.

来源：2024 Global Trends in AI by S&P Global

构建AI-ready Data

AI-ready Data: 经过处理后的、高质量且适合用于人工智能模型训练、推理或决策支持的数据。



Garbage in, Garbage out
通过质量、标准等治理手段，提升训练数据的准确性、完整性，减少噪音影响，从而提升AI的准确度。

数据质量



整合各部门的数据，避免数据孤岛，促进跨团队协作；便捷访问多个来源的数据，确保数据的多样性，推动模型快速迭代。

数据可访问性



技术手段（如加密、脱敏）和管理策略（如访问控制、合规框架）相结合，保护数据安全，规避隐私数据的泄漏风险。

数据隐私安全




给数据赋予更多的属性，丰富数据集的元数据信息，让AI能够更好地“理解”数据，从而提升AI输出的准确度。

元数据丰富度


02 现代数据架构的设计

新兴数据架构 — Data Lakehouse



来源: data-mozart.com

新兴数据架构 — Data Fabric




来源：Gartner


■ Lakehouse与Fabric的协同

相互协同		降本提效，释放数据价值，助力业务增长		
Data Fabric	★ 架构理念	● 数据民主化	● 统一访问入口	● 数据虚拟化
	● 产品视角	业务人员自助访问业务数据，无需长链路的同步加工，打破数据孤岛。	用户通过单一接口查询分散在本地、云端的数据，无需物理迁移。	通过数据虚拟化技术屏蔽物理层，为用户提供统一的逻辑数据视图。
Data Lakehouse	★ 技术底座	● 开放的湖表格式	● 流批融合计算	● 存算分离
	● 技术视角	湖表支持不同场景的引擎访问，无需复制数据。并且支持ACID、TimeTravel等特性。	基于同一份存储，同时支持流批的读写，流批计算不再有清晰的边界。	存储与计算完全分离，可以在低廉的存储上，运行任意的计算引擎。


多云、多引擎的现代数据架构




现代数据架构 — One Catalog



现代数据架构 — 存算分离




现代数据架构 — 数据虚拟化




03 现代数据架构在产品中的落地


多云、多引擎、多模式入湖




多云、多引擎、多模式入湖 – 增全量集成




多云、多引擎、多模式入湖 – 增全量集成




■ 流批融合计算





流批融合计算 – 流批任务依赖




查询加速





查询加速 — 一键切换模式



多渠道消费




多渠道消费 – 多引擎插件



04 Data for AI的总结与展望

Raw Data -> AI-ready Data


Raw Data



从无序走向有序



AI-ready Data



基于现代数据架构的建设、治理、消费链路，构建高质量、易获取、易理解、安全可靠的数据

知识库：让AI看懂数据

补充信息


- 资产的标签、属性、使用说明
- 补充质量报告、探查报告等
- 补充业务信息

企业知识库

- 企业私域知识文档
- 统一的词根、码表、标准
- 答疑QA



开放集成：让AI访问数据



📍 北京

QCon

全球软件开发大会

会议时间：4月10-12日

- 大模型赋能 AIOps
- 越挫越勇的大前端
- 云上业务架构演进
- 多模态大模型及应用
- 海外 AI 应用创新实践

📍 北京

AiCon

全球人工智能开发与应用大会

会议时间：6月27-28日

- 端侧智能
- AI Agent
- 多模态大模型
- 金融+大模型

📍 上海

QCon

全球软件开发大会

会议时间：10月23-25日

- AI Agent
- 大模型训练推理
- 端侧 AI
- 搜推深度融合
- 数智金融

4月

5月

6月

8月

10月

12月

📍 上海

AiCon

全球人工智能开发与应用大会

会议时间：5月23-24日

- 通用大模型
- AI Agent
- 垂直领域应用
- 模型可解释性

📍 深圳

AiCon

全球人工智能开发与应用大会

会议时间：8月22-23日

- 模型效率与部署
- 多模态大模型
- 大模型安全
- 智能硬件

📍 北京

AiCon

全球人工智能开发与应用大会

会议时间：12月19-20日

- 通用大模型
- 智能硬件
- LMOPs
- 具身智能

极客邦科技 2025 年会议规划

促进软件开发及相关领域知识与创新的传播



参会咨询



查看会议

THANKS

探索 AI 应用边界

Explore the limits of AI applications

AiCon

全球人工智能开发与应用大会